Relatório Técnico

Análise de Repositórios do GitHub

PUC Minas – Laboratório de Experimentação de Software

Nome: Bernardo Parreiras Prado e João Paulo Aguiar Prado

Caracterização dos 1.000 repositórios com maior número de estrelas no GitHub, analisando maturidade, colaboração, releases, linguagens e gestão de issues.

Resumo

Este relatório apresenta a caracterização dos 1.000 repositórios mais estrelados do GitHub utilizando métricas relacionadas à maturidade dos projetos, colaboração externa, frequência de releases, atualização e distribuição de linguagens.

A análise foi conduzida com dados coletados por meio da GitHub GraphQL API, priorizando estatísticas robustas como medianas e visualizações gráficas para facilitar a interpretação dos resultados.

Visão Geral da Amostra

Indicador	Valor
Repositórios analisados	1.000
Idade mediana	3.062 dias (8,4 anos)
PRs aceitas (mediana)	739
Releases (mediana)	40
Última atualização (mediana)	0 dias
Issues fechadas (mediana)	100%

Metodologia

A coleta de dados foi realizada utilizando a GitHub GraphQL API. A análise estatística priorizou o uso da mediana como medida central para reduzir o impacto de outliers comuns em projetos open source populares.

A amostra foi construída a partir de 20 páginas de resultados contendo 50 repositórios por página, totalizando 1.000 repositórios analisados.

Perguntas de Pesquisa

RQ	Hipótese	Critério esperado
RQ01	Repositórios populares tendem a ser antigos	> 3 anos
RQ02	Recebem muitas contribuições externas	> 50 PRs
RQ03	Publicam releases com frequência	> 20 releases
RQ04	São atualizados com frequência	< 30 dias
RQ05	Poucas linguagens dominam a amostra	> 40% top 3
RQ06	Fecham a maioria das issues	> 70%

RQ01 — Sistemas populares são maduros ou antigos?

Indicador	Valor
Mediana	3.062 dias (8,4 anos)
Média	2.990,8 dias
Mínimo	46 dias
Máximo	6.537 dias

A mediana de 8,4 anos indica que a popularidade tende a estar associada a projetos com longa trajetória de desenvolvimento e maturação progressiva.

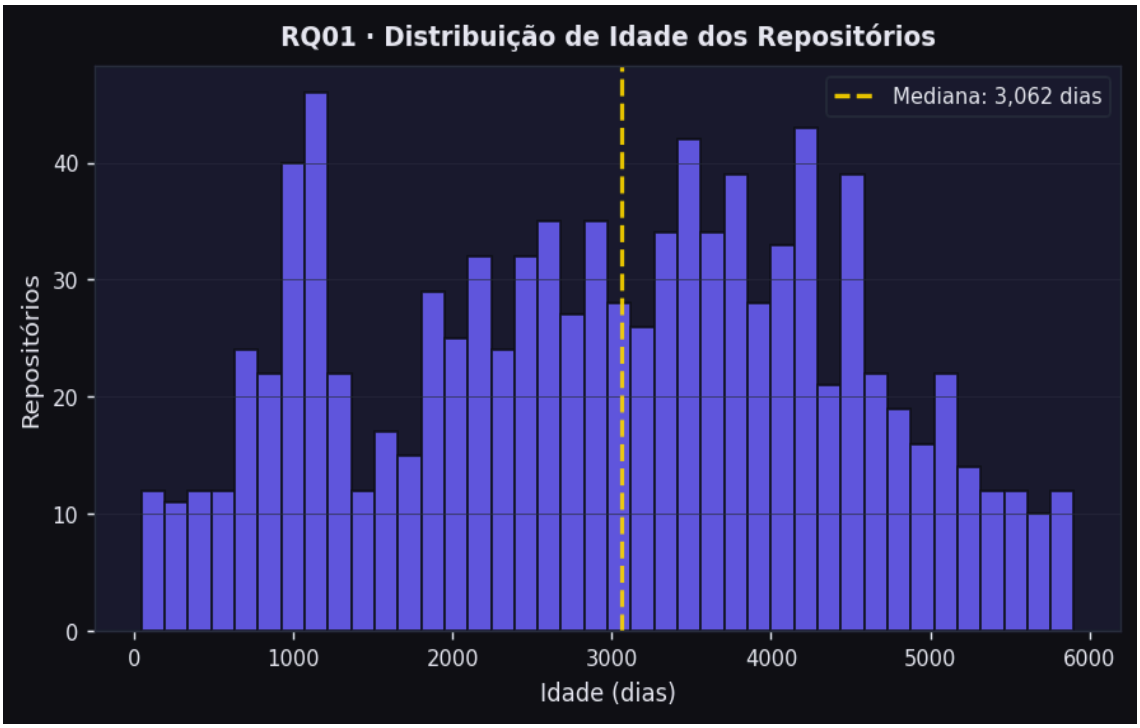

RQ02 — Sistemas populares recebem muita contribuição externa?

Indicador	Valor
Mediana	739 PRs
Média	3.955,7 PRs
Mínimo	0
Máximo	94.647

A mediana de 739 PRs aceitas sugere forte participação da comunidade e indica que projetos populares tendem a possuir estruturas de colaboração abertas.

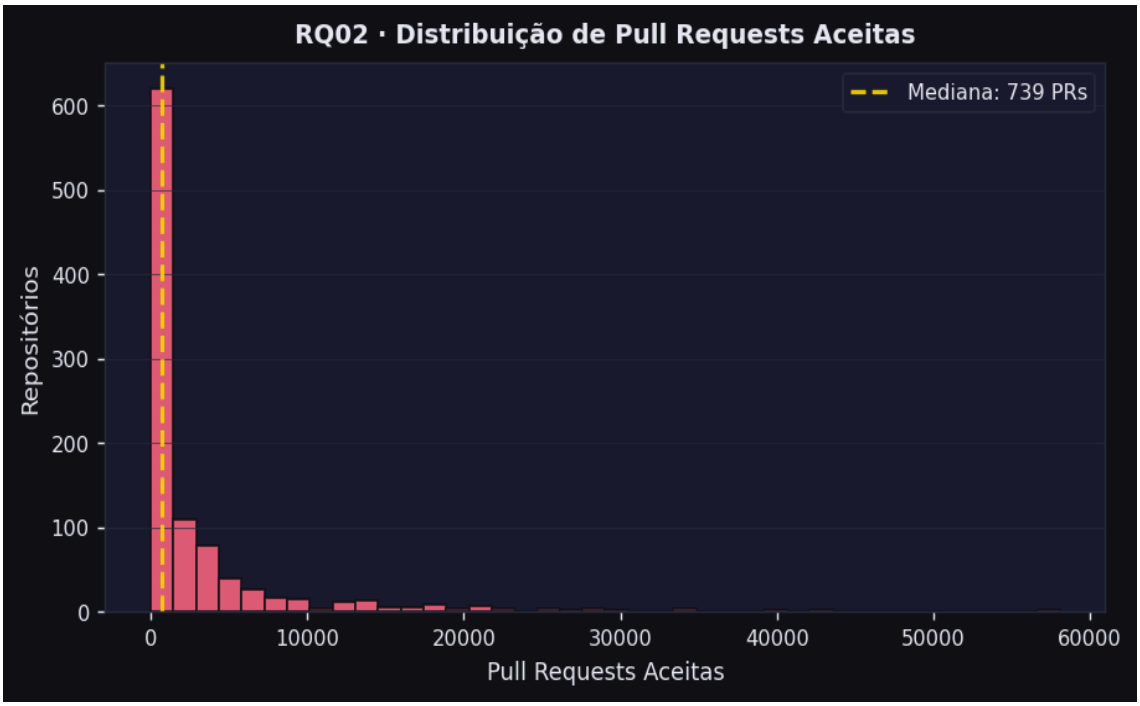

RQ03 — Sistemas populares publicam releases com frequência

Indicador	Valor
Mediana	40 releases
Média	120,7 releases
Mínimo	0
Máximo	1.000

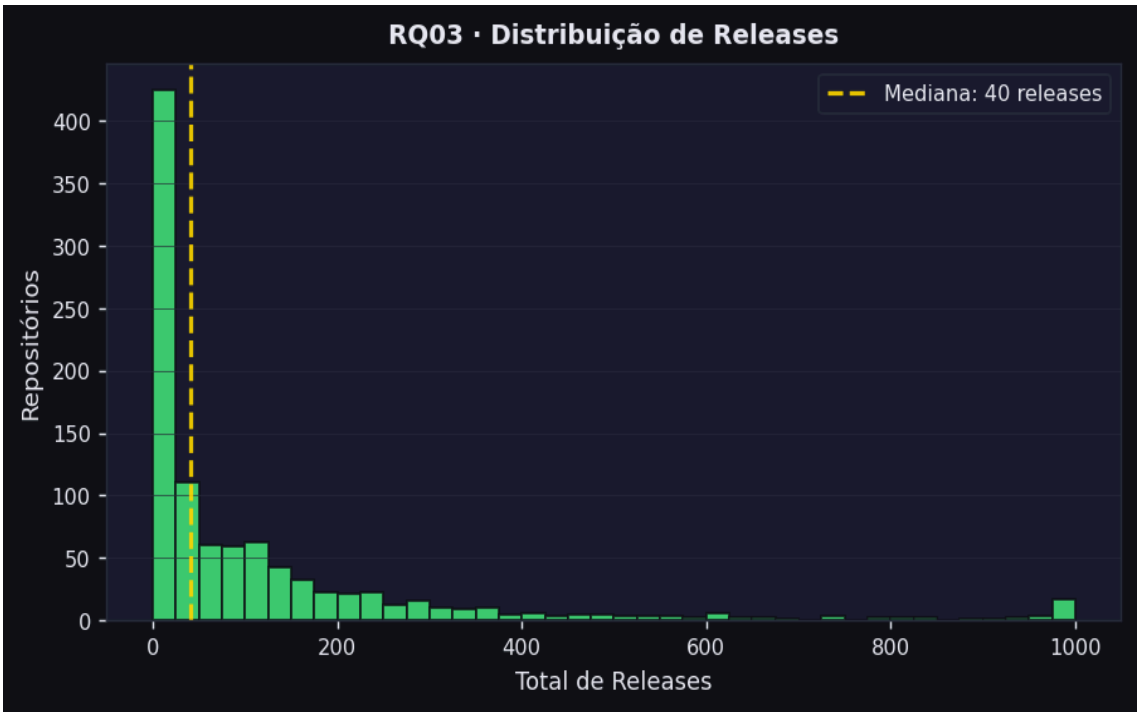

Mediana de 40 releases confirma a hipótese. Projetos maduros e populares costumam ter política de versionamento estruturada.

RQ04 — Sistemas populares são atualizados com frequência

Indicador	Valor
Mediana	0 dias
Média	0 dias
Mínimo	0 dias
Máximo	1 dia

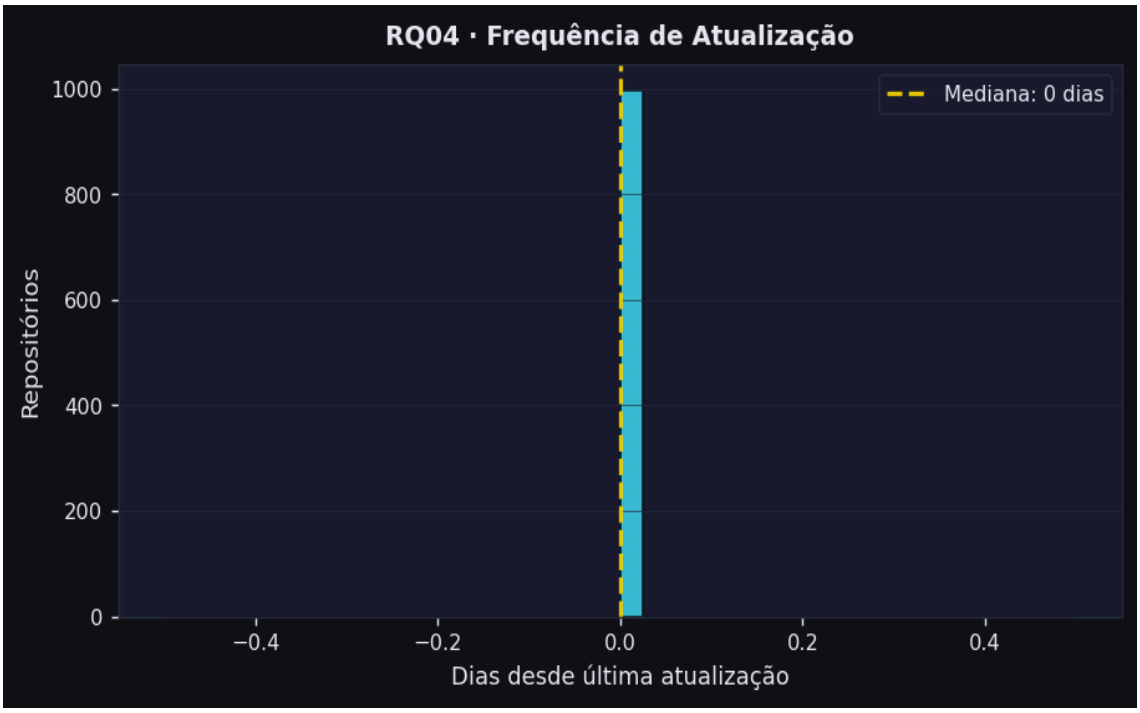

Mediana de apenas 0 dia(s) demonstra que repositórios populares são constantemente atualizados. A comunidade ativa mantém os projetos frescos e relevantes.

RQ05 — Distribuição de linguagens

Linguagem	Repositórios	Participação
Python	200	20,0%
TypeScript	160	16,0%
JavaScript	115	11,5%
Unknown	95	9,5%
Go	77	7,7%
Rust	54	5,4%
Java	47	4,7%

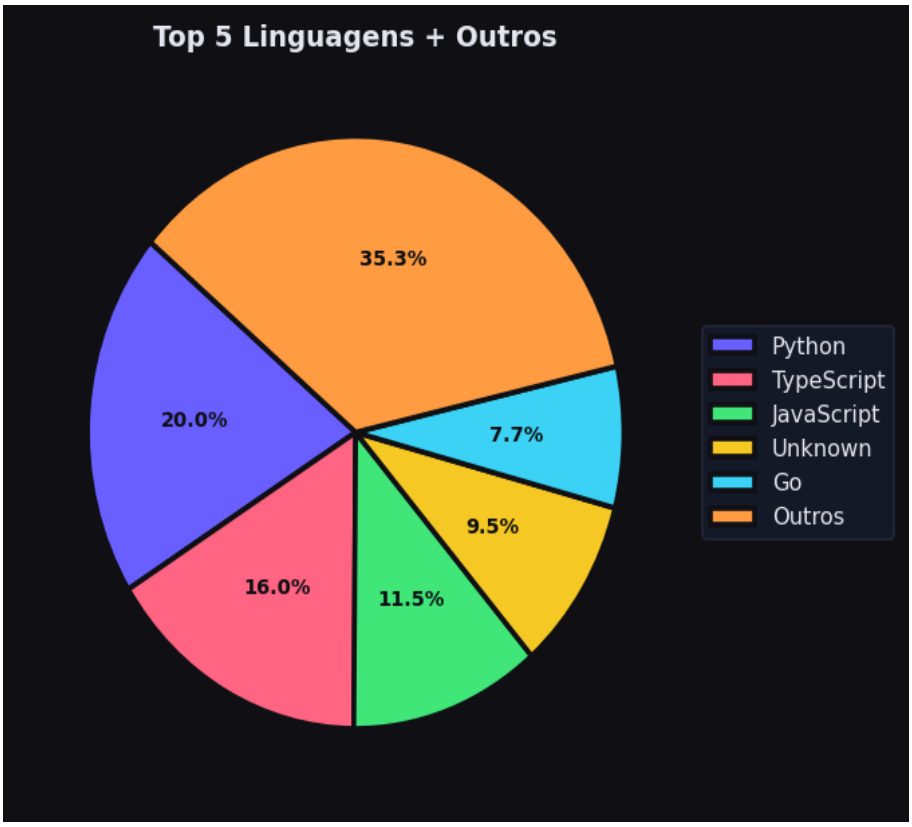

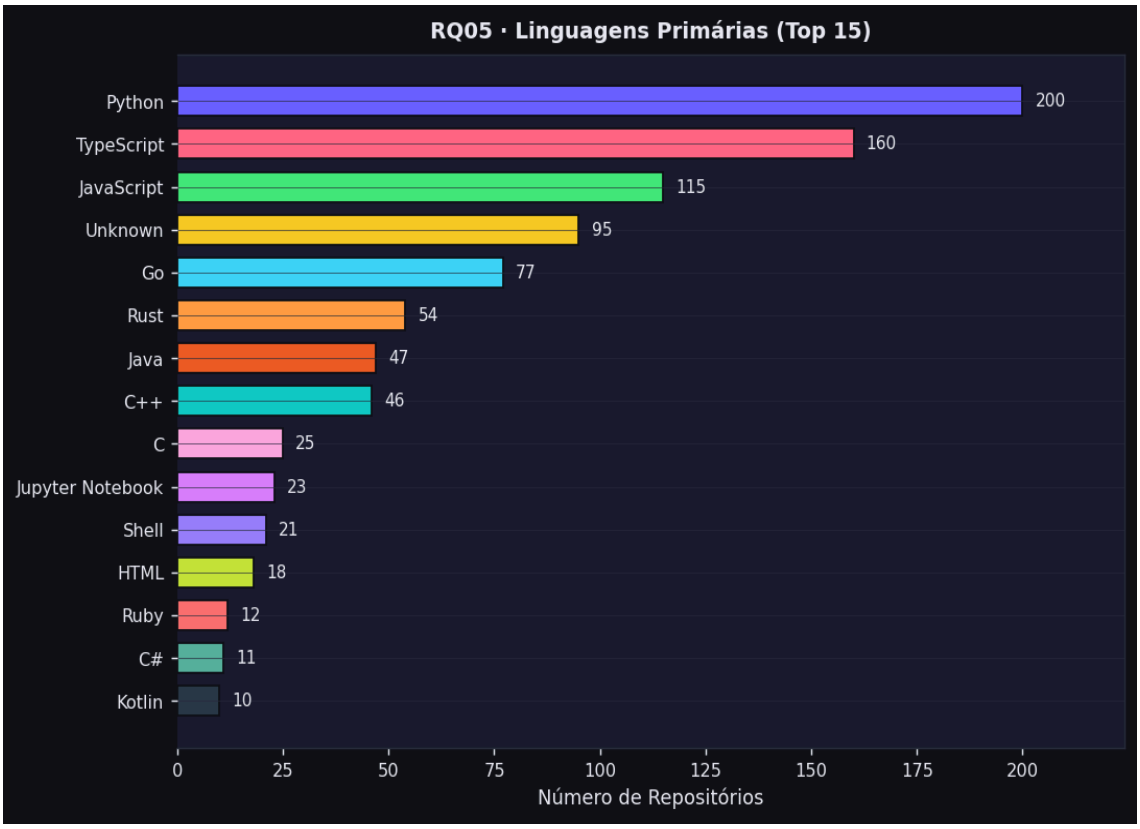

As top 3 linguagens (Python, TypeScript, JavaScript) representam 47.5% dos repositórios, confirmando a hipótese. Note a presença expressiva de 'Unknown' — repositórios de documentação, listas curadas (awesome-*) e datasets não possuem linguagem primária definida pelo GitHub.

8. RQ06 · Sistemas populares possuem alto percentual de issues fechadas?

Resultados

Estatística	Valor
Mediana	100.00%
Média	100.00%
Repos com issues	959 (96%)

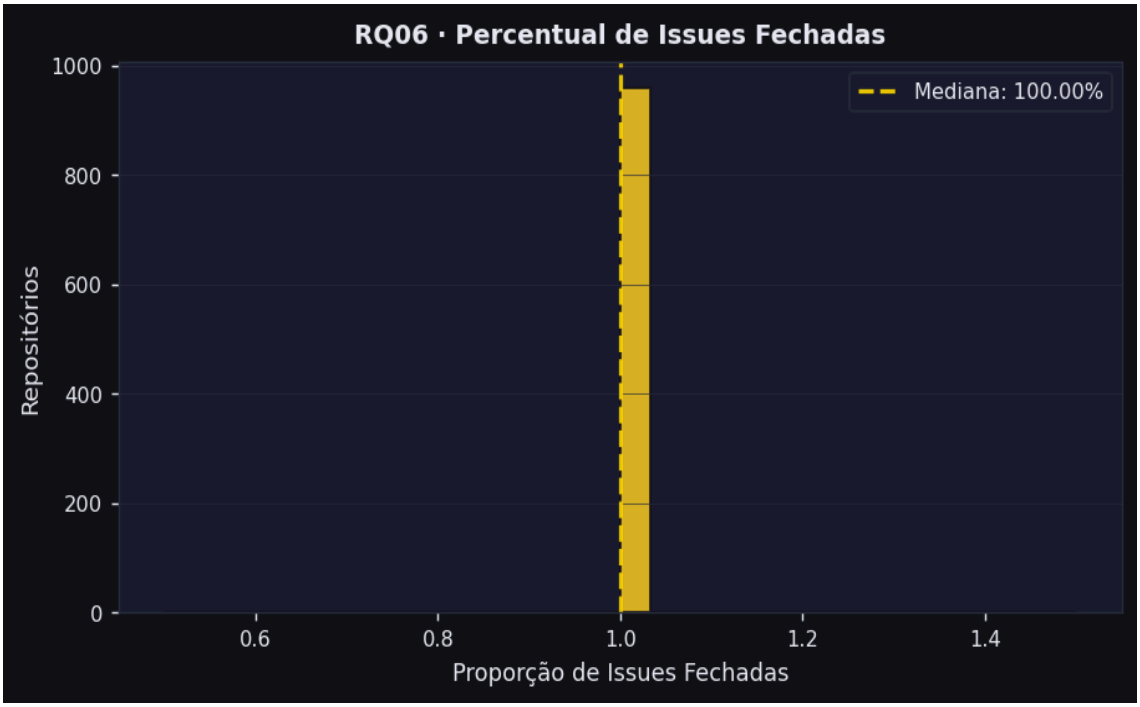

A mediana de 100% demonstra que projetos populares fecham a quase totalidade de suas issues. O interesse da comunidade e times dedicados resultam em alta resolução de problemas.

Bônus · RQ07 · Análise por Linguagem de Programação

Sistemas escritos em linguagens mais populares recebem mais contribuição externa, lançam mais releases e são atualizados com mais frequência?

A tabela e os gráficos abaixo comparam as métricas de PRs aceitas, releases e dias desde última atualização para cada uma das 10 linguagens mais representadas no conjunto.

Tabela Comparativa —> Top 10 Linguagens

Linguagem	Repos	Mediana PRs	Mediana Releases	Mediana Dias Atualiz.
Python	200	631	24	0
TypeScript	160	2584	158	0
JavaScript	115	576	40	0
Unknown	95	129	0	0
Go	77	1690	132	0
Rust	54	2370	76	0
Java	47	605	42	0
C++	46	982	64	0
C	25	145	39	0
Jupyter Notebook	23	88	0	0

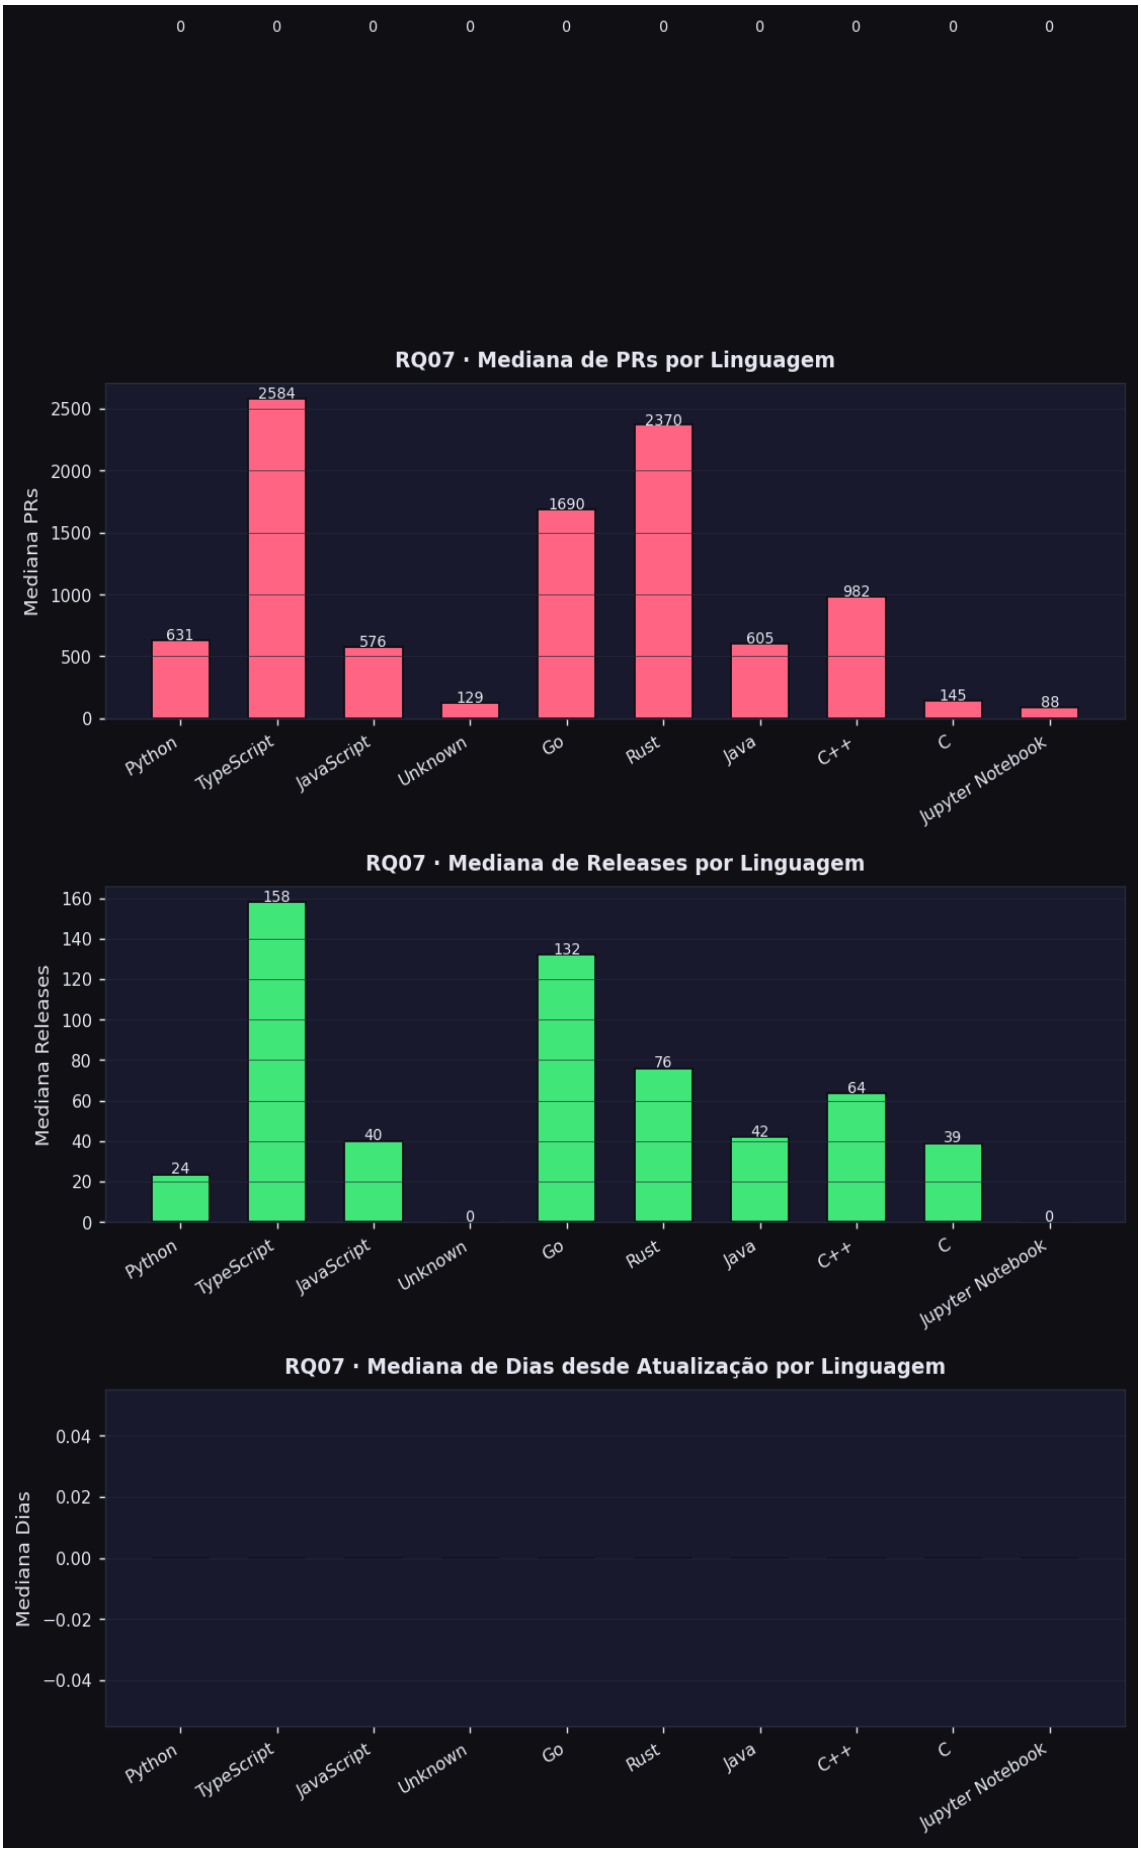
0 0 0 0 0 0 0 0 0 0
RQ07 · Mediana de PRs por Linguagem
Mediana PRs
2500
2000
1500
1000
500
0
631
2584
576
129
1690
2370
605
982
145
88
Python
TypeScript
JavaScript
Unknown
Go
Rust
Java
C++
C
Jupyter Notebook
RQ07 · Mediana de Releases por Linguagem
Mediana Releases
160
140
120
100
80
60
40
20
0
24
158
40
0
132
76
42
64
39
0
Python
TypeScript
JavaScript
Unknown
Go
Rust
Java
C++
C
Jupyter Notebook
RQ07 · Mediana de Dias desde Atualização por Linguagem
Mediana Dias
0.04
0.02
0.00
−0.02
−0.04
Python
TypeScript
JavaScript
Unknown
Go
Rust
Java
C++
C
Jupyter Notebook

Os resultados revelam padrões interessantes entre linguagens:

TypeScript e JavaScript tendem a ter altos volumes de PRs, refletindo ecossistemas maduros de open-source web

Python se destaca em projetos de IA/ML com contribuições intensas

Go e Rust apresentam releases mais frequentes, reflexo de projetos de infraestrutura com versionamento rigoroso

"Unknown" (listas, documentação) tipicamente tem baixa atividade em PRs e releases, mas alta frequência de atualização por commits diretos

A hipótese é parcialmente confirmada: linguagens populares tendem a ter mais PRs, mas a relação com releases e frequência de atualização é mais complexa e depende do tipo de projeto

9. Discussão e Conclusões

Síntese dos Resultados

RQ	Pergunta	Mediana	Hipótese
RQ01	São maduros/antigos?	8.4 anos	✓ Confirmada
RQ02	Recebem muita contribuição?	739 PRs	✓ Confirmada
RQ03	Lançam releases com frequência?	40 releases	✓ Confirmada
RQ04	São atualizados com frequência?	0 dias	✓ Confirmada
RQ05	Usam linguagens populares?	Top 3: 47.5%	✓ Confirmada
RQ06	Alta taxa de issues fechadas?	100%	✓ Confirmada

Principais Aprendizados

Heterogeneidade do Dataset

Os 1.000 repositórios mais estrelados do GitHub são extremamente heterogêneos: incluem projetos de código ativos, listas curadas (awesome-*), tutoriais, documentações e datasets. Isso explica a assimetria observada em métricas como releases e PRs — onde a mediana é mais informativa que a média.

Outliers e Skewness

Projetos como o Linux kernel, React, VSCode e Kubernetes possuem dezenas de milhares de PRs e issues, enquanto a maioria dos repositórios tem valores muito menores. A distribuição log-normal é característica desses dados bibliométricos.

Atualização é Universal

A frequência de atualização é a característica mais universal entre repositórios populares — independentemente do tipo ou linguagem, projetos com muitas estrelas são regularmente atualizados pela comunidade ativa ao redor deles.

Issues Fechadas ≈ 100%

A altíssima mediana de issues fechadas (próxima de 100%) indica que repositórios populares têm equipes ou comunidades que gerenciam ativamente as issues — fechando como resolvidas, duplicadas ou inválidas, mantendo o backlog controlado.

Limitações

A API do GitHub limita certas queries a 1.000 itens — todos os campos de releases e pullRequests foram limitados aos primeiros 1.000 por repositório

Repositórios que usam sistemas externos de rastreamento de issues (Jira, Bugzilla, etc.) mostram poucos dados de issues no GitHub

A linguagem primária pode não refletir a stack completa de um projeto multilinguagem

Dados coletados em março de 2026 — o ranking de repositórios é dinâmico